

Predicción de la variabilidad espacio-temporal del $PM_{2.5}$ mediante el uso de datos satelitales en centros urbanos de América Latina

Lic. Josefina Urquiza

Contenido

Introducción general.

Propuesta metodológica.

Sitios de estudio.

Evaluación de la performance de las observaciones satelitales de AOD.

Potencial del AOD satelital para la predicción de $PM_{2.5}$

Aprendizaje automático aplicado a la estimación de $PM_{2.5}$

Contribución del AOD satelital a la predicción espacio-temporal del $PM_{2.5}$

Conclusiones generales.

1.

Introducción general

¿Por qué surge esta tesis?

1. Problemática global: Contaminación atmosférica

*La **contaminación del aire** es hoy uno de los grandes desafíos ambientales y de salud pública a nivel global.*

4.2M

Muertes prematuras atribuibles a la contaminación del aire

1/8

Muertes provocó la contaminación atmosférica

2do

Factor de riesgo más importante a nivel mundial

(OMS, 2024; Health Effects Institute 2025)



1. Entendiendo la contaminación atmosférica

¿Qué es?

Presencia de sustancias en el aire en concentraciones que pueden afectar negativamente la salud humana, los ecosistemas o los materiales.

¿Cuál es su efecto?

La magnitud de estos impactos depende de la concentración, tiempo de exposición y de la vulnerabilidad de las poblaciones afectadas.

Control de Calidad del Aire

Contaminantes criterio

Sustancias reguladas con estándares establecidos basados en la salud

	Periodo	Niveles 2005	Niveles 2021
PM _{2.5}	Anual	10 ug/m ³	5 ug/m ³
	24 horas	25 ug/m ³	15 ug/m ³
PM ₁₀	Anual	20 ug/m ³	15 ug/m ³
	24 horas	50 ug/m ³	45 ug/m ³
O ₃	Temporada Pico	-	60 ug/m ³
	8 horas	100 ug/m ³	100 ug/m ³
NO ₂	Anual	40 ug/m ³	10 ug/m ³
	24 horas	-	25 ug/m ³
SO ₂	24 horas	20 ug/m ³	40 ug/m ³
CO	24 horas	20 mg/m ³	40 mg/m ³

Valores guía OMS recomendados para cada contaminante criterio

1. Material particulado (PM)

Control de Calidad del Aire


Contaminantes criterio

Sustancias reguladas con estándares establecidos basados en la salud

	Periodo	Niveles 2005	Niveles 2021
PM_{2.5}	Anual	10 ug/m ³	5 ug/m ³
	24 horas	25 ug/m ³	15 ug/m ³
PM₁₀	Anual	20 ug/m ³	15 ug/m ³
	24 horas	50 ug/m ³	45 ug/m ³
O₃	Temporada Pico	-	60 ug/m ³
	8 horas	100 ug/m ³	100 ug/m ³
NO₂	Anual	40 ug/m ³	10 ug/m ³
	24 horas	-	25 ug/m ³
SO₂	24 horas	20 ug/m ³	40 ug/m ³
CO	24 horas	20 mg/m ³	40 mg/m ³

Valores guía OMS recomendados para cada contaminante criterio

Clasificación según diámetro aerodinámico



1. Estrategias para el monitoreo de la calidad del aire

Los **contaminantes atmosféricos varían en el espacio y en el tiempo**, debido a la heterogeneidad de fuentes de emisión, condiciones meteorológicas variables y procesos atmosféricos complejos.

Monitoreo Discreto



Muestreadores Pasivos

Sistemas que recolectan muestras de aire sin bombeo activo.

Muestreadores Activos

Utilizan una bomba para hacer pasar un volumen de aire conocido a través de un medio de recolección.



Monitoreo Continuo



Analizadores Automáticos

Miden contaminantes en tiempo real con alta precisión.

Sensores de Bajo Costo

Dispositivos compactos que permiten una red de monitoreo más densa.





Teledetección Satelital

Observa los contaminantes desde el espacio para una cobertura a gran escala.

Eje central de esta tesis!

1. Monitoreo superficial de la calidad del aire en América Latina

Históricamente, el **monitoreo** en **América Latina** ha sido **limitado y desigual** entre países, una situación que persiste hasta la actualidad.



1. Teledetección satelital como herramienta complementaria

Problema en la región

La escasez de monitoreo superficial dificulta obtener una imagen completa del estado de la calidad del aire.

Teledetección satelital: herramienta valiosa


Obtiene información sobre la atmósfera y la superficie terrestre a distancia, a partir de sensores ópticos instalados en satélites.

Predicción $PM_{2.5}$

La Profundidad Óptica de Aerosoles (AOD) sirve como un predictor.



Sensores (Plataformas satelitales) más utilizadas para la recuperación de aerosoles (AOD)



MAIAC C6.1

Multi-Angle Implementation of Atmospheric Correction

1. Uso del AOD satelital como predictor de $PM_{2.5}$



Ambos describen la carga de partículas en la atmósfera

$PM_{2.5}$




AOD



Partículas finas que respiramos cerca del suelo y que afectan directamente la salud



Carga total de aerosoles en toda la columna atmosférica




Ejemplo gráfico de la relación entre AOD satelital y $PM_{2.5}$ superficial.

1. Objetivo general

*Analizar el potencial del **AOD satelital** como principal predictor de **PM_{2.5}**, en combinación con **otras variables ambientales** (provenientes de plataformas satelitales, modelos atmosféricos, entre otras), mediante la comparación de **modelos** de distinta complejidad, con el fin de caracterizar la **variabilidad espacio-temporal** de las concentraciones en **centros urbanos de América Latina**.*



1. Objetivos específicos



2.

Propuesta metodológica

¿El AOD satelital es un buen predictor del $PM_{2.5}$ a nivel superficial?

1

Desempeño del AOD satelital frente a la red AERONET

2

Relación simple $PM_{2.5}$ - AOD

3

Incorporación de variables predictivas adicionales
Modelos mas complejos


4

Variabilidad espacio-temporal del $PM_{2.5}$ en los centros urbanos seleccionados

Enfoque comparativo para analizar la capacidad predictiva del AOD para estimar $PM_{2.5}$

3.

Sitios de estudio



Mapa de ubicación de ciudades sobre uso de suelo
(MODIS MOD12Q1, 500 m)

? Como seleccionamos los sitios

- ✓ Área metropolitana >2 millones de hab.
- ✓ Estaciones AERONET (AOD superficial)
- ! Estaciones de monitoreo de $PM_{2.5}$

Periodo de estudio

2015-2024

4.

Evaluación de la performance de las observaciones satelitales de AOD en centros urbanos de América Latina.

¿El AOD satelital es un buen predictor del $PM_{2.5}$ a nivel superficial?

1

Desempeño del AOD satelital frente a la red AERONET

2

Relación simple $PM_{2.5}$ - AOD

3

Incorporación de variables predictivas adicionales
Modelos mas complejos



4

Variabilidad espacio-temporal del $PM_{2.5}$ en los centros urbanos seleccionados

Objetivos:

- 1 Analizar la variabilidad temporal del AOD superficial.
- 2 Evaluar el desempeño de MAIAC C6.1
- 3 Examinar la influencia de la resolución espacial en el desempeño a través de la comparativa entre MAIAC C6.1 y DT .
- 4 Comparar el desempeño de las versiones C6.0 y C6.1 de MAIAC para evaluar el impacto de las modificaciones.


4. Metodología



Métricas estadísticas

R^2 , RMSE, Bias


Incertidumbre Relativa Expandida (REU).



Estaciones AERONET (círculo central) y área de influencia de 25 km (línea punteada), sobre cobertura del suelo.

4. Resultados

4. Influencia de la resolución espacio-temporal en el desempeño de MAIAC C6.1



Ventana temporal

Impacto mínimo

Uso de ventana = ± 60 min.

Ventana espacial

Sensibilidad al tamaño de la ventana

Escalas finas (1-5 km): R^2 $\uparrow$ (0.88), RMSE $\downarrow$ (~ 0.07)

Escalas gruesas (15-25 km): R^2 $\downarrow$ (0.22), RMSE $\uparrow$ (~ 0.11).

En la mayoría de sitios: ligera $\downarrow$ de REU

Resolución mas fina (1 km): mejor desempeño, capta variabilidad intra-urbana.

4. Desempeño MAIAC C6.1 a 1 km (pixel)

Dos grupos de sitios
Según nivel de AOD y desempeño

SP, MX, ST ↑

AOD_{AERONET} mayor

Mejor desempeño

R² mayor

Bias tiende a subestimar

Menor REU (%)

BA, LP, (MD) ↓

AOD_{AERONET} menor

Desempeño mas pobre

R² menor


Bias tiende a sobrestimar

Mayor REU (%)

RMSE similar entre sitios



Para baja carga de aerosoles, la señal de AOD es más débil y se vuelve más difícil de distinguir del ruido de la superficie de la reflectancia, aumentando la incertidumbre en la recuperación.




4.

Los resultados muestran que el producto AOD de **MAIAC C6.1 (1 km)** alcanza un **desempeño moderado** frente a las mediciones de referencia de la red AERONET, lo que lo posiciona como una variable **potencialmente útil** para la estimación de concentraciones superficiales de **PM_{2.5}**



5.




Potencial del AOD satelital para la predicción de $PM_{2.5}$




Objetivos:

- 1 Conocer los niveles de $PM_{2.5}$ en los centros urbanos seleccionados.
- 2 Evaluar la relación directa entre el AOD satelital y el $PM_{2.5}$.
- 3 Analizar el efecto de incorporar variables predictoras adicionales y correcciones al AOD en los modelos predictivos
- 4 Comparar el desempeño de distintos modelos predictivos.

5. Metodología



5. Modelos predictivos



Simple
↓
Variables complementarias
↓
Flexibles
↓
Aprendizaje automático

Modelos predictivos

01

Regresión lineal simple (RLS)
RLS Corrección atmosférica por BLH-RH

02

Regresión Lineal Múltiple (RLM)
Regresión Ridge
Regresión LASSO

03

Modelo Lineal Generalizado (GLM)
Modelo lineal mixto (LME)
Modelo aditivo generalizado (GAM)

04

Regresión de Vectores de Soporte (SVR)
Random Forest (RF)
Extremely Randomized Trees (ExtraTrees-ET)
eXtreme Gradient Boosting (XGB)

5.

Resultados

5. Regresión Lineal Simple (RLS) y la influencia de la meteorología

Punto de referencia, para evaluar qué tan bien el AOD, por sí solo, puede explicar las concentraciones en superficie.


Potencial del AOD para la predicción de $PM_{2.5}$

Desempeño pobre: de $R^2 < 0.5$ y RMSE elevados.

LP y BA sitios con menores valores y MX los mas altos.

Correcciones aplicadas, mejoraron las métricas de desempeño.

Persisten limitaciones.



Métricas de desempeño obtenidas para cada tipo de corrección en comparación con RLS.

Necesidad de modelos más robustos

5. Regresión Lineal Múltiple (RLM)


Aporte de predictores adicionales

R^2 aumentó respecto a la RLS (Max. 0.17-MX), hasta modelo final de RLM (0.36-BA y 0.57-ST).


RMSE se redujo entre un 20 y 30% respecto a la RLS.

Efecto **meseta** en el desempeño: NDVI y composición de aerosoles.

Todavía existe margen para optimizar la capacidad predictiva de los modelos.




Estructura progresiva de los modelos predictivos construidos.




Variabilidad de métricas de desempeño con la incorporación progresiva de variables.

Ridge vs LASSO




Manejar la multicolinealidad y reducir el sobreajuste

Modelo Lineal Generalizado (GLM)




Generaliza RL permitiendo supuestos sobre la distribución del error

Modelo Lineal Mixto (LME)



Incorpora efectos fijos y aleatorios que corresponde a la variabilidad no explicada

Modelo Aditivo Generalizado (GAM)



Modela efectos flexibles mediante funciones suaves sin imponer una forma funcional rígida

5.

Todavía existe **margen para optimizar** la capacidad predictiva de los modelos.



¿El AOD satelital es un buen predictor del $PM_{2.5}$ a nivel superficial?	
1	Desempeño del AOD satelital frente a la red AERONET
2	Relación simple $PM_{2.5}$ - AOD
3	Incorporación de variables predictivas adicionales Modelos mas complejos
4	Variabilidad espacio-temporal del $PM_{2.5}$ en los centros urbanos seleccionados

6.

Aprendizaje automático aplicado a la estimación de $PM_{2.5}$

Objetivos:

- 1 Diseñar y entrenar los modelos predictivos basados en técnicas de aprendizaje automático.
- 2 Evaluar la capacidad de generalización de los modelos.
- 3 Comparar el desempeño de distintos modelos predictivos.
- 4 Explorar el aporte del AOD satelital en la predicción del $PM_{2.5}$.

6. Metodología

Simplex
↓
Variables complementarias
↓
Flexibles
↓
Aprendizaje automático

Modelos predictivos

01

Regresión lineal simple (RLS)
RLS Corrección atmosférica por BLH-RH

02

Regresión Lineal Múltiple (RLM)
Regresión Ridge
Regresión LASSO

03

Modelo Lineal Generalizado (GLM)
Modelo lineal mixto (LME)
Modelo aditivo generalizado (GAM)

04

Regresión de Vectores de Soporte (SVR)
Random Forest (RF)
Extremely Randomized Trees (Extra-Trees-ET)
eXtreme Gradient Boosting (XGB)

Esquemas de validación cruzada (CV)

CV aleatoria (K Fold=10)

CV espacial (leave-one-station-out)

CV temporal (leave-one-year-out)

Iteración 1	Test	Train	Train	Train	Train
Iteración 2	Train	Test	Train	Train	Train
Iteración 3	Train	Train	Test	Train	Train
Iteración 4	Train	Train	Train	Test	Train
Iteración 5	Train	Train	Train	Train	Test

6.

Resultados

6. Evaluación de la capacidad de generalización

Necesidad de evaluar su capacidad de generalización frente a datos no utilizados en el entrenamiento

Desempeño

Mejora de métricas de desempeño en comparación con los modelos “mas simples”.

Validación cruzada aleatoria

La validación aleatoria arrojó los **mejores** resultados de desempeño


Validación cruzada espacial

Disminución del R^2 10% - 20% y **aumento** del RMSE en proporciones similares.

Validación cruzada temporal

Mayor variabilidad, con **fluctuaciones** en R^2 entre -10% y +10% y **aumentos** de RMSE entre 5% y 15%.


Importancia de usar validaciones más exigentes



Comparación de métricas por sitio y modelo según el esquema de validación. R: aleatorio; E: espacial; T: temporal.

6. Aporte del AOD satelital en la predicción de $PM_{2.5}$

Mejores modelos



Efecto de la exclusión del AOD

R^2 : Disminución MD, MX y ST


RMSE: Aumenta MD, MX y ST

Bias (absoluto):

- Aumenta: MX y MD
- Disminuye: ST

SP y BA no se observan cambios notables.

AOD satelital aporta información adicional
a la predicción de $PM_{2.5}$, aunque su efecto
varía según el sitio



Regresiones lineales para el modelo seleccionado en cada caso. Modelos con AOD como predictor (*). Modelos sin AOD (*).

6.

Los **modelos de aprendizaje automático** superaron el desempeño de los “modelos más simples”, coincidiendo en la identificación de las variables predictoras más relevantes y en el aporte del AOD satelital.

La inclusión del AOD mejoró la predicción de $PM_{2.5}$, con mayor efecto en MD, MX y ST y menor relevancia en SP y BA.



¿El AOD satelital es un buen predictor del $PM_{2.5}$ a nivel superficial?	
1	Desempeño del AOD satelital frente a la red AERONET
2	Relación simple $PM_{2.5}$ - AOD
3	Incorporación de variables predictivas adicionales Modelos mas complejos
4	Variabilidad espacio-temporal del $PM_{2.5}$ en los centros urbanos seleccionados



7.

Contribución del AOD satelital a la predicción espacio-temporal del $PM_{2.5}$

Objetivos:

- 1 Aplicar los modelos seleccionados para estimar el $PM_{2.5}$ (año 2024).
- 2 Analizar la contribución del AOD satelital en la predicción de $PM_{2.5}$ (a nivel espacial y temporal).
- 3 Caracterizar la variabilidad espacio-temporal del $PM_{2.5}$.

7. Metodología



A) Imagen satelital de AOD MAIAC original y B) interpolación del AOD con IDW



Stack de variables predictivas seleccionadas.

7.

Resultados

7. Análisis temporal del aporte de AOD a la predicción


ST, MX y BA: mejores predicciones con AOD

SP: diferencias mínimas

MD, la baja variabilidad mensual provocó que ambos modelos se superpongan con las observaciones.

Ambos modelos capturan la estacionalidad observada.

La inclusión del **AOD aporta información** complementaria,
pero no constituye un factor decisivo para **mejorar las predicciones mensuales**.



Promedio mensual de $PM_{2.5}$ observado vs estimado (Modelos con/sin AOD, 2024)

7. Análisis espacial del aporte de AOD a la predicción



No permiten inferir si implica una mejora o un deterioro en la calidad de la predicción.

SP

Gradiente latitudinal

ST

Gradiente longitudinal

MD

Zona central vs periferias


MX

Zona sur y oeste

BA

Patrón es más irregular y segmentado, con bandas alternadas de diferencias positivas y negativas





El **AOD** satelital **aporta información espacial relevante**, aunque **no garantiza** por sí solo una **mejora** en la predicción



7. Variabilidad espacial anual de PM_{2.5} para el año 2024 – Modelo AOD

Todos los sitios presentan gradientes en zonas de mayor densidad poblacional.

Todos los dominios superan las directrices de la OMS (5 µg/m³)



PM_{2.5} anual por sitio (dominio) frente al umbral recomendado por la OMS (5 µg/m³).

8.

Conclusiones generales



Conclusiones generales

- El AOD satelital por sí solo no permite estimaciones robustas de PM_{2.5}, pero→ es un predictor valioso cuando se integra con variables meteorológicas, de superficie y de aerosoles.
- Comparación metodológica: modelos “simples” vs modelos de aprendizaje automático
- Aportes del AOD en términos temporales y espaciales
- La integración de estas metodologías permite caracterizar de manera más completa la variabilidad espacio-temporal del PM_{2.5} en centros urbanos de la región.
- Todos los centros urbanos analizados registraron concentraciones anuales por encima del umbral recomendado por la OMS (5 µg/m³) para el año 2024, lo que pone de manifiesto un problema generalizado de calidad del aire no saludable en la región.

